



Facultad de
Ciencias
UNAM

Proyecto Final - Módulo 8: Demanda y generación eléctrica en Estados Unidos

Raúl Llamosas Alvarado

Eumir Rendon Uresti
Randy Jesús García Mejía

Gabriela Peña Franco

Daniela Ibarra Gatica
Daniela Vázquez Sánchez

Table of contents

Introducción	1
Problema y contexto	1
Pregunta principal	1
Datos y procedencia	2
Alcance	2
Principales decisiones de limpieza	2
Metodología	2
Modelo	2
Principales resultados	3
Conslusiones	3
Limitaciones	3
Posibles extensiones	3

Introducción

Todo nuestro código se encuentra en el [siguiente repositorio de GitHub](#). Con el dashboard presentado en la exposición localizado en la [siguiente URL](#). En el `README.md` del repositorio se explican algunas funcionalidades de como está montado. Como por ejemplo la actualización de la información de forma automática por medio de GitHub Actions.

Problema y contexto

El sistema eléctrico de Estados Unidos tiene una demanda que cambia por hora, día, semana y estación. También es influida por clima actividad humana y características regionales. Sufre de apagones. Y tiene picos de demanda.

Pregunta principal

Como tal no elegimos una pregunta principal, intentamos contestar de manera visual las siguientes:

- ¿Es posible anticipar los periodos de máxima demanda?
- ¿Qué variables explican los picos de consumo?
- ¿Cómo cambia el mix de generación durante el día?
- ¿En qué condiciones aumenta la participación de fuentes renovables?
- ¿Qué regiones presentan comportamientos similares?

Pero en el uso del modelado contestamos las referentes a las condiciones metereológicas y su peso en la demanda eléctrica.

Datos y procedencia

Para este proyecto usamos tres fuentes básicamente:

- **EIA**: Sus siglas significan U.S Energy Information Administration, de aquí sacamos la mayoría de la información usada por el dashboard. Cosas como demanda de electricidad, capacidad de los generadores, las ventas en millones de dolares que se obtiene por el suministro de electricidad, provienen de este dataset.
- **ODIN**: Este es un departamento liderado por Oak Ridge National Laboratory (ORNL) y la Oficina de Electricidad del Departamento de Energía de Estados Unidos (DOE). De esta base sacamos la información pertinente a los apagones que sufre el sistema de electricidad estadounidense.
- **Open-Meteo**: Usamos Open-Meteo para conseguir información meteorológica y poder predecir de cierta manera la generación eléctrica usando energías renovables.

Alcance

Para la Demanda, el alcance es nacional. No quisimos hacerlo muy granular porque se volvía más difícil. Lo mismo para las ventas. Caso contrario, para la predicción de generación eléctrica con energía renovables, como las condiciones climáticas afectan de forma regional, optamos por tener un alcance de una sola área metropolitana, San Diego. Que se encuentra en California, justo en la frontera con Tijuana, Baja California.

Principales decisiones de limpieza

Para la información proveniente de EIA la limpieza consistió de cambiar el tiempo UTC al horario central que es el que se usa en la Ciudad de México. Esto nos sirvió para hacerlo homogéneo y hacer un merge entre los datos de la EIA con los de Open-Meteo.

Metodología

Descargar por medio de la API de EIA, la demanda histórica para toda la región contigua de Estados Unidos para un periodo de 2021 a 2026. Se tuvieron que hacer 10 llamadas a la API para extraerlo todo.

Modelo

Dado que la demanda para toda la zona contigua de Estados Unidos, conocida como US48 es cíclica, utilizamos como modelo a XGBoost, esto dado nuestras previas experiencias con el buen desempeño de este modelo y también debido al carácter no lineal de la demanda. La demanda puede ser influida por factores externos como la composición demográfica de los Estados Unidos, así como condiciones climáticas. Estas características no las pudimos incluir con más bases porque eran o inaccesibles o muy difíciles de incluir en un solo dataset para entrenar y probar. Una regresión lineal no capturaría estos detalles así como no capturaría cosas como días festivos, feriados o cualquier otro evento.

XGBoost: forecast vs real (2 semanas de test)




Figure 1: XGBoost: forecast vs real (2 semanas de test)

Este fue el desempeño del entrenamiento ML para calcular la demanda eléctrica. De igual manera, usamos XGBoost para predecir la generación eléctrica por tipo de energía renovable. Hicimos un modelo por energía renovable para no tener un modelo “every size fits all”. Por lo que tenemos 4 modelos:

- xgb_GEO.model
- xgb_SUN.model
- xgb_WAT.model
- xgb_WIND.model

Cada uno tiene sus features que sacamos de Open-Meteo, por ejemplo para el de generación por medio de energía solar usamos cosas que fueran relevantes como lo son si el día es soleado o nublado, etc. Lo mismo para el resto de modelos, para el de WIND la velocidad del viento. Etc.

Principales resultados

- Patrón ciclico en la demanda de electricidad
- Patrones en la distribución del tipo de energía usada, como por ejemplo luz solar en ciertos horarios
- Patrón de ventas con dos generadores en particular, el que abastece a California y Texas siendo los más redituables.

Conslusiones

Con el uso del modelo ML de XGBoost para predecir la demanda mas toda la información de ODIN+EIA, el dashboard logra mostrar de forma visual y efectiva el estado actual del sistema eléctrico de Estados Unidos. Con algunas limitaciones, como veremos a continuación.

Limitaciones

- La información de apagones proveniente de ODIN es bastante pobre, no tiene mucha información respecto al status o causa de los apagones.
- En el caso de EIA, la información que viene es demasiado *descriptiva*, es decir, no nos ayuda mucho a poder generar un modelo para predecir cosas que no sean demanda o generación eléctrica. Para poder crear un dataset más robusto tendríamos que hacer muchas mezclas con el censo demográfico o condiciones climáticas, pero nos dimos cuenta que era una tarea muy extensa y pesada, dado que todos estos datasets tenían sus detalles de formato.
- La información de Open-Meteo es por ciudad, pero la información de generación eléctrica es por generador, lo cual no siempre es descriptivo ya que un generador puede abastecer a multiples ciudades o regiones enteras. Notamos que esto afectó nuestra capacidad de predecir la generación eléctrica con energías renovables.

Posibles extensiones

Enriquecer más el proyecto con información de censos y condiciones climáticas sería un buen punto de partida para enriquecer más el dashboard.