



Proyecto Final - Módulo 8: Demanda y generación eléctrica en Estados Unidos

Raúl Llamosas Alvarado

Eumir Rendon Uresti

Gabriela Peña Franco

Daniela Ibarra Gatica

Randy Jesús García Mejía

Daniela Vázquez Sánchez

Table of contents

Introducción	1
Problema y contexto	1
Pregunta principal	2
Hipótesis	2
Datos y procedencia	2
Obtención de los datos	2
Alcance	2
Exploración y calidad de los datos	2
Exploración de las condiciones asociadas a la generación	3
Principales decisiones de limpieza	3
Metodología	3
Modelos	4
Modelo de demanda	4
Modelos de generación renovable	5
Principales resultados	5
Demanda eléctrica	5
Condiciones asociadas a la generación renovable	5
Conclusiones	5
Limitaciones	5
Posibles extensiones	5

Introducción

El sistema eléctrico de Estados Unidos combina una demanda que cambia a lo largo del tiempo con una generación proveniente de distintas fuentes y una creciente participación de tecnologías renovables. Esta dinámica genera un problema de análisis con dos dimensiones complementarias: por un lado, anticipar cambios de corto plazo en la demanda eléctrica y, por otro, comprender bajo qué condiciones meteorológicas y temporales se observa una mayor generación de fuentes renovables.

El objetivo de este proyecto es integrar datos públicos de electricidad, clima y apagones para construir una visión descriptiva del sistema eléctrico estadounidense y desarrollar modelos de aprendizaje automático que permitan evaluar su capacidad predictiva. El análisis combina información de la U.S. Energy Information Administration (EIA), Open Energy Data Initiative (ODIN) y Open-Meteo.

Los resultados se presentan mediante un dashboard interactivo que permite explorar la demanda, generación, ventas, capacidad y apagones del sistema eléctrico. El código utilizado para reproducir el análisis se encuentra en el [siguiente repositorio de GitHub](#) y el dashboard está disponible en la [siguiente URL](#).

Problema y contexto

La demanda eléctrica de Estados Unidos presenta patrones temporales asociados con la hora del día, el día de la semana y la estación del año. Además, existen periodos de demanda elevada que requieren una respuesta adecuada del sistema de generación. Al mismo tiempo, la generación a partir de fuentes renovables depende de condiciones que varían en el tiempo.

El problema abordado en este proyecto consiste en identificar patrones que permitan comprender estos comportamientos y evaluar si las variables disponibles contienen información suficiente para realizar predicciones de corto plazo.

Pregunta principal

El análisis se centra en dos preguntas principales:

- ¿Es posible anticipar los periodos de máxima demanda?
- ¿En qué condiciones aumenta la participación de fuentes renovables?

La primera pregunta se aborda directamente mediante un modelo de predicción de la demanda de los siguientes días. La segunda se estudia mediante el análisis de los patrones de generación renovable y la evaluación de modelos que utilizan variables meteorológicas y temporales como predictores.

Hipótesis

A partir de las características de los datos y del procedimiento de modelado desarrollado, se plantean las siguientes hipótesis:

- **Demanda:** los patrones temporales y los valores recientes de la demanda contienen información suficiente para anticipar la demanda eléctrica de los siguientes días y, con ello, proporcionar información útil para anticipar periodos de demanda elevada.
- **Generación renovable:** las condiciones meteorológicas y los patrones temporales están relacionados con la generación de distintas fuentes renovables; sin embargo, la capacidad de predicción puede variar entre tecnologías debido a sus características físicas y a la diferencia entre la escala de cobertura de los datos meteorológicos y la de los generadores.

Datos y procedencia

El proyecto utiliza tres fuentes principales.

- **U.S. Energy Information Administration (EIA).** Se utilizó como fuente principal para la información del sistema eléctrico. De esta fuente se obtuvieron datos horarios de demanda de la región US48, generación por tipo de combustible, capacidad de generación y ventas de electricidad.
- **Open Energy Data Initiative (ODIN).** Se utilizó para incorporar información sobre apagones a nivel de condado, incluyendo variables relacionadas con la causa, ubicación, estado del incidente y número de medidores afectados.
- **Open-Meteo.** Se utilizó para obtener información meteorológica horaria que posteriormente se relacionó con la generación renovable de California.

Obtención de los datos

La demanda US48 se obtuvo mediante la API de EIA realizando múltiples llamadas para extraer toda la información. De igual modo, la generación de energía renovable por tipo de combustible se obtuvo de EIA. Se consultaron las fuentes GEO, SUN, WAT y WND para el área de balance de California (CISO).

La información meteorológica se descargó mediante la API histórica de Open-Meteo para San Diego, California. Se consultaron variables horarias relacionadas con radiación solar, nubosidad, viento, temperatura, presión, precipitación y otras condiciones meteorológicas.

La información sobre los apagones se obtuvo mediante la API de ODIN, extrayendo la ubicación y la causa de las fallas eléctricas.

Alcance

El análisis de demanda, ventas, capacidad y apagones tiene un alcance nacional, con el objetivo de mantener una visualización manejable y concentrar el dashboard en patrones generales del sistema eléctrico de Estados Unidos.

Para el análisis de generación renovable se utiliza una escala regional. La generación corresponde al área de balance de California (CISO), mientras que las variables meteorológicas corresponden a San Diego, California. Es un buen punto de referencia ya que California, se reconoce por su alto consumo de energía (que podemos notar en el dashboard en la sección de ventas)

En cuanto al periodo, se consideró información desde enero de 2021 hasta septiembre de 2026.

Exploración y calidad de los datos

Antes del modelado se revisó la estructura y la calidad de las bases utilizadas. La base histórica de demanda no contiene valores faltantes en la variable de demanda o registros duplicados por periodo.

Los valores promedio de la demanda muestran un patrón estacional: el promedio mensual más elevado de la serie corresponde a julio, seguido de agosto.

Para el conjunto de generación renovable y clima se construyó por hora con cuatro tipos de fuente: solar (SUN), eólica (WND), hidráulica (WAT) y geotérmica (GEO). No se conservaron registros duplicados por combinación de hora y fuente.

La generación presenta diferencias importantes entre tecnologías. Estas diferencias justifican la decisión de entrenar un modelo separado para cada fuente, en lugar de utilizar un único modelo para todas las tecnologías.

Exploración de las condiciones asociadas a la generación

La exploración también muestra relaciones distintas entre las fuentes y las variables meteorológicas. Por ejemplo, en la información integrada la generación solar presenta una asociación positiva fuerte con la radiación de onda corta y con la radiación normal directa, mientras que la nubosidad presenta una asociación negativa.

En el caso de la generación eólica, la relación con las variables meteorológicas es menos marcada que en el caso solar. La correlación con la velocidad del viento es una de las variables consideradas en el modelo, sin embargo, esta por sí sola podría resultar insuficiente para la predicción.

Para la generación hidráulica, las relaciones simples también son más débiles. Esto es consistente con la necesidad de incorporar información adicional para representar adecuadamente fenómenos que pueden depender de acumulación de agua, condiciones hidrológicas y características específicas de las cuencas.

Principales decisiones de limpieza

La principal decisión de limpieza fue homologar las referencias temporales antes de combinar las fuentes. Los datos provenientes de EIA y los datos meteorológicos se transformaron al horario central que es el que se usa en la Ciudad de México.

No se consideran aquellas incidencias de los apagones que no cuentan con ubicación.

Para las energías renovables, se descartan columnas correspondiendo de la siguiente manera:

```
features <- list(
  SUN = c("shortwave_radiation", "direct_normal_irradiance",
    "diffuse_radiation", "cloud_cover", "cloud_cover_low",
    "cloud_cover_mid", "temperature_2m",
    "hour_sin", "hour_cos", "doy_sin", "doy_cos"),
  SNB = c("shortwave_radiation", "direct_normal_irradiance",
    "cloud_cover", "cloud_cover_low", "temperature_2m",
    "hour_sin", "hour_cos", "doy_sin", "doy_cos"),
  WND = c("wind_speed_80m", "wind_speed_120m", "wind_cubed_80m",
    "wdir80_sin", "wdir80_cos", "wind_gusts_10m",
    "temperature_80m", "surface_pressure",
    "hour_sin", "hour_cos", "doy_sin", "doy_cos"),
  WAT = c("precipitation", "temperature_2m", "snow_depth",
    "et0_fao_evapotranspiration",
    "hour_sin", "hour_cos", "doy_sin", "doy_cos"),
  GEO = c("temperature_2m", "hour_sin", "hour_cos",
    "doy_sin", "doy_cos")
)
```

Se eliminaron de todas las bases los valores nulos.

Metodología

En la demanda se descompuso la fecha en hora, día de la semana y mes, además de crear una variable indicadora de fin de semana. Para representar la dependencia temporal se construyeron rezagos de 1, 24, 48 y 168 horas, así como medias móviles de 24 y 168 horas.

```
df <- datos %>%
  mutate(
    hour      = hour(period),
    dow       = wday(period),          # 1 = domingo
    month     = month(period),
    is_weekend = dow %in% c(1, 7),

    lag_1h    = lag(demand, 1),
    lag_24h   = lag(demand, 24),
    lag_48h   = lag(demand, 48),
    lag_168h  = lag(demand, 168),

    roll_24h  = zoo::rollmeanr(demand, 24, fill = NA),
    roll_168h = zoo::rollmeanr(demand, 168, fill = NA),

    target    = lead(demand, 1)
  ) %>%
  na.omit()
```

Para la generación renovable se construyeron variables cíclicas de la hora y la dirección del viento mediante seno y coseno.

```
df <- df %>%
  filter(!is.na(generation), generation > 0) %>%
  mutate(
    period_utc = ymd_hms(period_utc, tz = "UTC"),
    hour_pt    = hour(with_tz(period_utc, "America/Los_Angeles")),
    dow        = wday(period_utc, week_start = 1),
```

```
month      = month(period_utc),
doy        = yday(period_utc),
hour_sin   = sin(2 * pi * hour_pt / 24),
hour_cos   = cos(2 * pi * hour_pt / 24),
doy_sin    = sin(2 * pi * doy / 365),
doy_cos    = cos(2 * pi * doy / 365),
wdir80_sin = sin(2 * pi * wind_direction_80m / 360),
wdir80_cos = cos(2 * pi * wind_direction_80m / 360),
wind_cubed_80m = wind_speed_80m^3
) %>%
arrange(period_utc)
```

Las transformaciones se realizaron para que las variables cíclicas no fueran tratadas como magnitudes lineales.

Para la generación renovable se integraron datos horarios de EIA y Open-Meteo. La generación corresponde al área de California y la información meteorológica corresponde a San Diego.

Se construyó un modelo independiente por tipo de fuente para evitar imponer la misma relación entre clima y generación a tecnologías con características diferentes. Los modelos considerados son:

- `xgb_SUN.model`: Generación solar.
- `xgb_WND.model`: Generación eólica.
- `xgb_WAT.model`: Generación hidráulica.
- `xgb_GEO.model`: Generación geotérmica.

Las variables utilizadas se seleccionaron de acuerdo con la naturaleza de cada fuente:

Fuente	Principales variables
Solar	Radiación de onda corta, radiación normal directa, radiación difusa, nubosidad, temperatura y variables temporales.
Eólica	Velocidad del viento a distintas alturas, dirección del viento, ráfagas, temperatura, presión y variables temporales.
Hidráulica	Precipitación, temperatura, nieve, evapotranspiración y variables temporales.
Geotérmica	Temperatura y variables temporales.

Asimismo, se contempló una reestructuración en el nivel de desagregación de la información, agrupando los distritos y regiones electricas a nivel estatal.

Modelos

Modelo de demanda

La prueba comienza el 25 de julio de 2025 y termina el 12 de septiembre de 2026. El alto R^2 y el MAPE relativamente bajo indican que el modelo reproduce con bastante precisión la variación de corto plazo de la demanda en el periodo de prueba, lo cual nos da evidencia de que la información es suficiente para anticipar la demanda de en un corto plazo.

XGBoost: forecast vs real (2 semanas de test)




Figure 1: XGBoost: forecast vs real (2 semanas de test)

Table 1: Métricas del modelo de predicción de demanda

demand	r2	rmse	mae	mape	n_train	n_test	train_end	test_start	test_end
US48_DEMAND	0.992	7647.57	5712.97	1.12	39820	9955	2025-07-25 03:00:00	2025-07-25 04:00:00	2026-09-12 22:00:00

Modelos de generación renovable

El desempeño de los modelos renovables fue heterogéneo.

Table 2: Métricas de modelos de generación renovable

fuel	r2	rmse	mae	mape	n_train	n_test	train_end
GEO	-1.496	76.62	63.25	8.29	5124	1282	2026-07-27 03:00:00
SUN	0.522	4070.80	3379.04	379.30	30880	7721	2025-08-01 04:00:00
WAT	0.032	1160.25	863.21	81.82	45811	11453	2025-08-08 18:00:00
WND	0.260	1274.69	1031.16	114.10	52248	13063	2025-06-16 14:00:00

El desempeño de los modelos varía significativamente según la tecnología, siendo el solar el que obtuvo la mayor R^2 , mientras que el modelo eólico obtuvo la segunda R^2 más alta manteniendo un MAR y RMSE equilibrados.

Por otro lado, el resultado de las métricas de los modelos hidráulico y geotérmico, principalmente una R^2 cercana a cero o negativa, evidencian que no se cuenta con información suficiente para predecir la variabilidad de la generación de estas energías.

Principales resultados

Demanda eléctrica

La exploración de la demanda muestra un comportamiento claramente temporal y cíclico, alcanzando sus valores más elevados en los meses de verano. Con los resultados obtenidos con el modelado de *XGBoost* obtuvimos evidencia de que la demanda de corto plazo es altamente predecible a partir de su comportamiento histórico y de patrones temporales. Por lo que si es posible anticipar los periodos de máxima demanda, respondiendo a la primera pregunta principal.

Condiciones asociadas a la generación renovable

Debido a las limitaciones predictivas obtenidas de los modelos de cada energía, no nos es posible establecer con la información recopilada de las fuentes las condiciones bajo las cuales incrementa la participación de todas las fuentes renovables. Sin embargo, con ayuda del visualizador si nos es posible ver que la energía solar usada incrementa en ciertos horarios.

Conclusiones

La demanda eléctrica en Estados Unidos guarda una estrecha relación con la actividad humana y las estaciones del año, lo que genera un comportamiento cíclico diario que facilita la predicción de los picos de consumo. Sin embargo, al incorporar las energías renovables, no se dispone de insumos suficientes para estimar con precisión su grado de participación en la cobertura de dicha demanda

Limitaciones

- La información de apagones proveniente de ODIN presenta cobertura y detalle limitados en algunas variables, por lo que su utilidad para construir modelos predictivos es restringida además de que podríamos sobre ajustar los modelos y no se podrían usar para estimar.
- La información de EIA es principalmente descriptiva para varias de las variables utilizadas. Para desarrollar modelos más completos sería necesario incorporar fuentes adicionales de información.
- Los modelos renovables utilizan un conjunto limitado de variables meteorológicas. La selección de variables y alturas de medición se realizó considerando las restricciones prácticas de consulta a la API y el conocimiento disponible sobre cada tecnología.

Posibles extensiones

Algunas de las posibles mejoras que se podrían considerar sería la incorporación de información demográfica y económica al modelo de demanda, así como la integración de conjuntos de datos más completos y representativos de cada fuente de energía.